# GymBeat: Sistema Vestível e Móvel para Contagem Automática de Repetições em Tempo Real em Exercícios Resistidos via Sensores Inerciais e Processamento Digital de Sinais

**José Pascoal Martins**[1], **Antonio Carlos Forster**[1]

[1]Faculdade de Engenharia de Computação – Pontifícia Universidade Católica de Campinas (PUC-Campinas) – Campinas, SP – Brasil

martinsj773@gmail.com, forster@puc-campinas.edu.br

***Abstract.*** *Automatic tracking of resistance exercises using smartwatches represents a key challenge in Human Activity Recognition (HAR). Most commercial solutions remain limited to macroscopic heart rate and caloric expenditure monitoring, lacking real-time repetition counting. This paper presents GymBeat, an integrated wearable and mobile system comprising an Apple Watch collector application written in Swift (CoreMotion / HealthKit / WatchConnectivity) and an iPhone companion application built with React Native / Expo and TypeScript. The watch samples triaxial acceleration and angular velocity at* $25\,Hz$ *and streams each inertial frame wirelessly to the smartphone via Bluetooth. On the mobile side, a pure-TypeScript inference engine synthesizes a 1D repetition trajectory through Moving Principal Component Analysis (Moving PCA) solved via the Power Iteration Method with skewness-based phase alignment, achieving orientation invariance without manual calibration. A causal biquad IIR low-pass Butterworth filter (*$f_c = 1.2\,Hz$*) paired with a Finite State Machine (FSM) performs sample-by-sample peak detection with warmup suppression (*$N \geq 8$*) and a physiological refractory lockout (*$t_{min} = 1.6\,s$*). All collected data is persisted locally in SQLite and synchronized to Firebase Cloud Firestore for research. Experimental validation with free barbell squats achieved an Exact Accuracy Rate of* $100\%$ *(*$MAE = 0.0$ *reps,* $RMSE = 0.0$*) with a computational latency below* $0.05\,ms$ *per sample on the Hermes JavaScript engine.*

***Resumo.*** *O monitoramento automático de exercícios resistidos (musculação) por meio de smartwatches representa um desafio central no Reconhecimento de Atividades Humanas (HAR). As soluções comerciais limitam-se ao registro cardiovascular e calórico, carecendo de contagem de repetições em tempo real. Este trabalho apresenta o GymBeat, um sistema vestível e móvel composto por um aplicativo coletor para Apple Watch desenvolvido nativamente em Swift (CoreMotion / HealthKit / WatchConnectivity) e um aplicativo companheiro para iPhone construído com React Native / Expo e TypeScript. O relógio amostra aceleração triaxial e velocidade angular a* $25\,Hz$ *e transmite cada quadro inercial via Bluetooth para o smartphone. No lado móvel, um motor de inferência em TypeScript puro sintetiza uma trajetória 1D de repetição através de* ***Análise de Componentes Principais Móvel (Moving PCA)*** *resolvida pelo* ***Método das Potências*** *com alinhamento de fase por assimetria (skewness), garantindo invariância de orientação sem calibração manual. Um filtro causal IIR biquad passa-baixa Butterworth (*$f_c = 1{,}2\,Hz$*) combinado a uma* ***Máquina de Estados***

***Finitos (FSM)*** *realiza detecção de picos amostra-a-amostra com supressão de aquecimento ($N \geq 8$) e bloqueio refratário fisiológico ($t_{min} = 1{,}6\,s$). Todos os dados coletados são persistidos localmente em SQLite e sincronizados ao Firebase Cloud Firestore. A validação experimental com agachamento livre atingiu $100\%$ de acerto exato ($MAE = 0{,}0$, $RMSE = 0{,}0$) com latência inferior a $0{,}05\,ms$ por amostra no motor Hermes.*

## 1. Introdução

A prática regular de exercícios físicos resistidos (musculação) é recomendada internacionalmente devido a seus efeitos benéficos no ganho de massa muscular, fortalecimento ósseo e preservação da saúde metabólica [American College of Sports Medicine 2018]. O controle estrito das repetições executadas em cada série é determinante para modular o estímulo fisiológico, a cadência sob tensão e prevenir lesões biomecânicas. Embora relógios inteligentes (*smartwatches*) contendo Unidades de Medição Inercial (IMUs) de tecnologia MEMS estejam amplamente difundidos em academias, a grande maioria das aplicações comerciais limita-se ao monitoramento passivo de frequência cardíaca e estimativas calóricas, carecendo de contagem fidedigna de repetições ao vivo.

A contagem em tempo real impõe três desafios fundamentais de engenharia e ciência da computação:

1. **Invariância de Orientação e Posicionamento:** O relógio pode rotacionar livremente no punho do praticante ou ser afivelado no braço dominante ou não dominante, de modo que os eixos ortogonais locais $(X, Y, Z)$ do sensor não coincidem com os eixos anatômicos do movimento;
2. **Ruídos Inerciais e Movimentos Parasitas:** Tremores musculares oriundos de fadiga, ajustes de pegada e hesitações na transição excêntrico-concêntrica geram perturbações de alta frequência que poluem o sinal;
3. **Restrições de Latência e Recursos Computacionais:** O processamento deve operar com consumo moderado de energia e latência imperceptível, dispensando modelos pesados de Aprendizado Profundo ou tráfego contínuo para servidores em nuvem.

Este trabalho propõe e valida o **GymBeat**, uma arquitetura distribuída entre Apple Watch e iPhone que realiza filtragem digital causal, projeção espacial adaptativa via Moving PCA com alinhamento por assimetria (*skewness*) e detecção de inflexões em tempo real, entregando retorno háptico imediato ao completar cada repetição. A solução baseia-se exclusivamente em princípios de Processamento Digital de Sinais e Álgebra Linear Leve, eliminando a dependência de aceleradores de hardware dedicados.

As principais contribuições deste artigo compreendem:

1. Arquitetura completa de coleta nativa, transmissão sem fio de baixa latência e inferência distribuída entre *smartwatch* e *smartphone*, com motor em TypeScript puro portável para qualquer interpretador JavaScript;
2. Formulação matemática robusta da síntese 6D $\rightarrow$ 1D via Moving PCA resolvida pelo Método das Potências com desambiguação de polaridade por coeficiente de assimetria amostral (*skewness*);
3. Validação experimental com dados reais de agachamento livre coletados por voluntários, alcançando $100\%$ de acurácia exata e latência de processamento de $0{,}045$ ms por amostra no motor Hermes.

## 2. Fundamentação Teórica

### 2.1. Computação Vestível e Sensores Inerciais (IMU)

Uma Unidade de Medição Inercial (IMU) é um sistema microeletromecânico (MEMS) composto fundamentalmente por um acelerômetro triaxial, que mede a aceleração específica $\mathbf{a}(t) = [a_x, a_y, a_z]^T$ em unidades de gravidade ($g \approx 9{,}81\,\text{m/s}^2$), e um giroscópio triaxial, que afere a velocidade angular instantânea $\boldsymbol{\omega}(t) = [\omega_x, \omega_y, \omega_z]^T$ em rad/s. No Apple Watch, o subsistema inercial é gerenciado pelo *framework* CoreMotion, que disponibiliza aceleração decomposta (*userAcceleration*) e vetor gravitacional isolados por filtros de Kalman embarcados [Bulling et al. 2014].

### 2.2. Biomecânica dos Exercícios Resistidos

Os exercícios resistidos com pesos livres baseiam-se em ciclos quase-periódicos divididos em três fases biomecânicas: (1) **fase excêntrica**, caracterizada pelo alongamento muscular sob tensão controlada; (2) **ponto de inflexão isométrico instantâneo**, onde a velocidade linear anula-se ($v(t) = 0$); e (3) **fase concêntrica**, marcada pela contração motora superando a sobrecarga externa [American College of Sports Medicine 2018]. No domínio inercial, cada repetição engendra uma onda com crista de aceleração acentuada durante o impulso concêntrico. A Figura 1 ilustra essa correspondência.

### 2.3. Limitações da Magnitude Euclidiana e Projeção via Moving PCA

A literatura clássica de HAR frequentemente adota a norma Euclidiana ($L_2$) para obter invariância à rotação do sensor: $\|\mathbf{a}(t)\|_2 = \sqrt{a_x^2 + a_y^2 + a_z^2}$. Contudo, por ser estritamente positiva, a norma colapsa acelerações e desacelerações de sentidos opostos em cristas indistintas, acarretando contagens duplicadas e perda da dinâmica direcional [Lara and Labrador 2013].

Para contornar essa restrição, o GymBeat emprega a **Análise de Componentes Principais Móvel (*Moving PCA*)** sobre uma janela deslizante de $N$ amostras recentes centralizadas. A matriz de covariância amostral $\mathbf{C} \in \mathbb{R}^{3\times3}$ é expressa por:

$$\mathbf{C} = \frac{1}{N}\sum_{k=1}^{N}(\mathbf{a}_k - \boldsymbol{\mu})(\mathbf{a}_k - \boldsymbol{\mu})^T, \quad \boldsymbol{\mu} = \frac{1}{N}\sum_{k=1}^{N}\mathbf{a}_k \tag{1}$$

O autovetor dominante $\mathbf{v}_1 \in \mathbb{R}^3$, associado ao maior autovalor $\lambda_1$, corresponde ao eixo primário de translação do exercício. Para calculá-lo de forma determinística e com complexidade estritamente limitada, utiliza-se o **Método das Potências (*Power Iteration*)** [Golub and Van Loan 2013], inicializado com $\mathbf{q}^{(0)} = [1/\sqrt{3}, 1/\sqrt{3}, 1/\sqrt{3}]^T$:

$$\mathbf{y}^{(k)} = \mathbf{C}\,\mathbf{q}^{(k-1)}, \quad \mathbf{q}^{(k)} = \frac{\mathbf{y}^{(k)}}{\|\mathbf{y}^{(k)}\|_2} \tag{2}$$

Com 25 iterações, a sequência atinge convergência estável em menos de $0{,}02$ ms no *smartphone*. A projeção escalar instantânea é obtida pelo produto interno:

$$p(t) = \mathbf{a}(t) \cdot \mathbf{v}_1 \tag{3}$$

A Figura 2 evidencia o contraste entre a magnitude $L_2$ e a projeção PCA 1D sobre uma série real de agachamento, destacando a preservação da morfologia concêntrica.

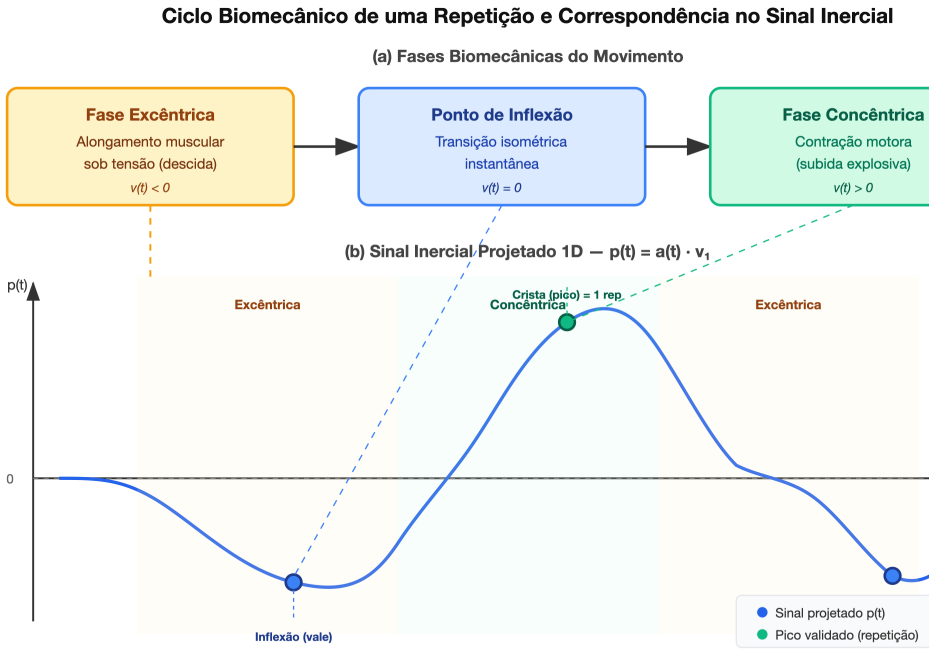



**Figura 1. Ciclo biomecânico de uma repetição e correspondência no sinal inercial projetado.**

## 2.4. Alinhamento de Polaridade via Assimetria (*Skewness*)

Como qualquer autovetor admite ambiguidade intrínseca de sinal ($\pm\mathbf{v}_1$), calcula-se o coeficiente de assimetria amostral (*skewness*) da projeção na janela deslizante:

$$\gamma_1 = \frac{\frac{1}{N}\sum_{i=1}^{N}(p_i - \bar{p})^3}{\left(\frac{1}{N}\sum_{i=1}^{N}(p_i - \bar{p})^2\right)^{3/2}} \tag{4}$$

Na biomecânica muscular, a fase concêntrica possui maior magnitude instantânea e menor duração temporal do que a fase excêntrica, induzindo $\gamma_1 > 0$. Caso obtenha-se $\gamma_1 < 0$, inverte-se o autovetor ($\mathbf{v}_1 \leftarrow -\mathbf{v}_1$), garantindo que a crista positiva do sinal represente consistentemente a fase concêntrica, independente de qual braço utiliza o relógio [Strang 2006]. A Figura 3 ilustra a correção de fase.

## 2.5. Filtragem Causal IIR Biquad

Para atenuação de ruídos de alta frequência sem exigir conhecimento de amostras futuras, implementa-se um filtro digital passa-baixa IIR Butterworth de 2ª ordem na Forma Direta

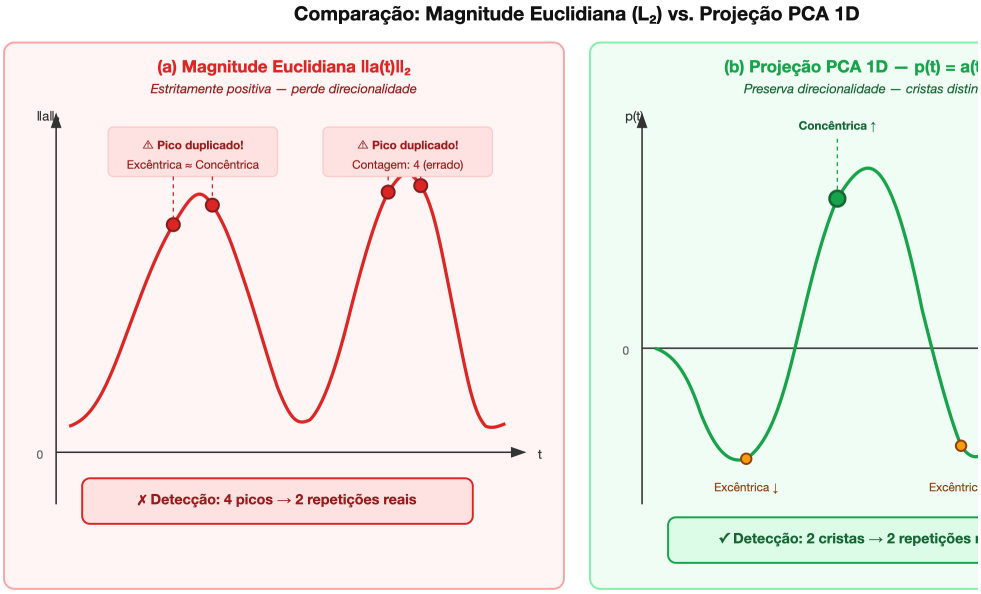



**Figura 2. Comparação visual entre Magnitude $L_2$ e Projeção PCA 1D para dados de agachamento livre.**

II Transposta [Oppenheim and Schafer 2009]:

$$y[n] = b_0\,x[n] + b_1\,x[n-1] + b_2\,x[n-2] - a_1\,y[n-1] - a_2\,y[n-2] \tag{5}$$

Os coeficientes são calculados em tempo de execução via transformação bilinear para a frequência de corte $f_c = \min(1{,}2\,\text{Hz},\ 0{,}40 \cdot f_s)$:

$$\omega_0 = \frac{2\pi f_c}{f_s}, \qquad \alpha = \frac{\sin(\omega_0)}{2\sqrt{2}} \tag{6}$$

A formulação assegura consumo de memória $O(1)$ e atraso de grupo inferior a $120\,\text{ms}$, mantendo o atraso imperceptível ao usuário. A Figura 4 apresenta a topologia do filtro e sua curva de resposta em frequência.

## 3. Arquitetura da Solução

### 3.1. Visão Geral

A arquitetura do GymBeat organiza-se em três camadas distribuídas, conforme ilustrado no diagrama em blocos da Figura 5:

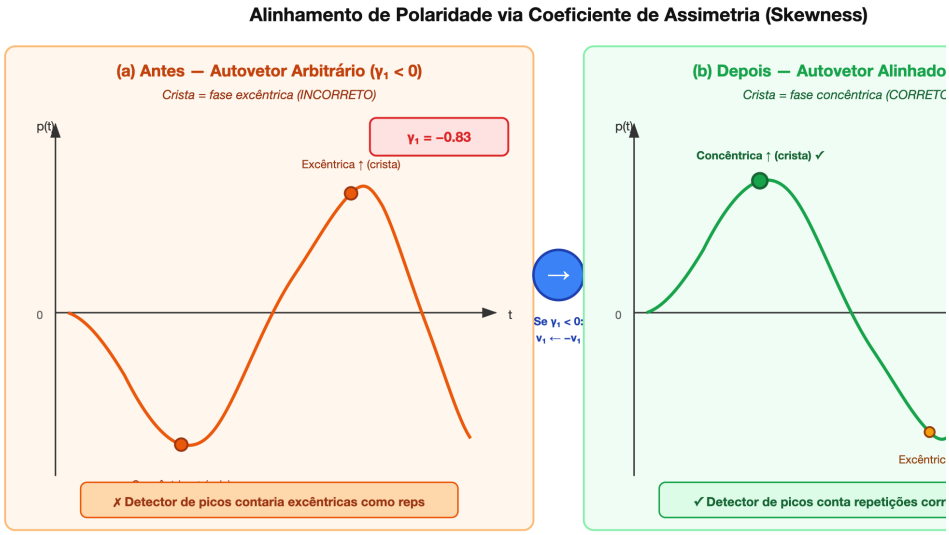



**Figura 3. Efeito do alinhamento por *skewness* na polaridade do sinal projetado.**

1. **Nó Coletor Vestível (Apple Watch):** Módulo nativo em Swift responsável pela amostragem inercial contínua (25 Hz) e transmissão sem fio via Bluetooth;
2. **Nó de Processamento Móvel (iPhone):** Aplicativo em React Native / Expo sobre o motor Hermes, executando o buffer circular, Moving PCA, filtro IIR e a máquina de estados finitos (FSM) de contagem, acionando retorno háptico instantâneo e persistindo séries no SQLite local;
3. **Nó em Nuvem (Firebase Firestore):** Repositório centralizado para armazenamento de treinos e sincronização em lote voltada à pesquisa acadêmica.

## 3.2. Módulo de Borda – Apple Watch

O nó coletor vestível foi implementado em Swift para watchOS. A Tabela 1 resume a configuração de hardware e *firmware* adotada.

A classe `WorkoutManager` orquestra a sessão ativa de treino, enquanto `WatchSessionManager` implementa o protocolo `WCSessionDelegate` para tratar comandos de controle originados no iPhone (`startSession`, `stopSession`, `pauseSession`, `resumeSession`, `appHeartbeat`). Cada quadro transmitido segue a estrutura tipada `MetricSample` contendo 11 canais sensoriais (Tabela 2). A Figura 6 detalha a máquina de estados de treino do relógio e o fluxo de comunicação bidirecional com o *smartphone*.

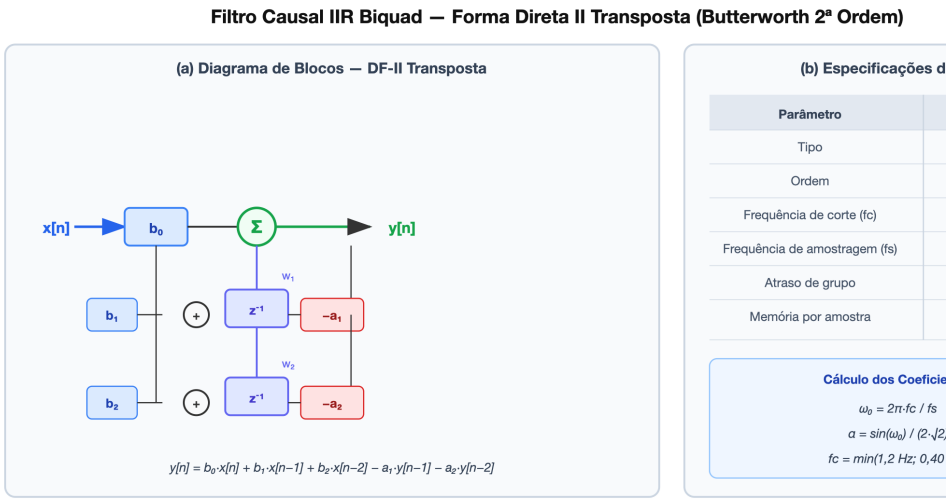



**Figura 4. Diagrama de blocos do filtro IIR Biquad e curva de atenuação em frequência.**

## 3.3. Camada de Transmissão e Persistência

### 3.3.1. Módulo Nativo WatchConnectivity (Expo Native Module)

A ponte de integração entre o subsistema WatchConnectivity do iOS e a camada JavaScript do React Native foi concebida como um Expo Native Module em Swift (`modules/watch-connectivity/`). O módulo exporta funções assíncronas (`sendCommand`, `getStatus`) e emite eventos tipados (`onWatchMessage`, `onWatchConnectivityChange`) com serialização de baixa latência.

### 3.3.2. Módulo Nativo HealthKit (Expo Native Module)

O módulo nativo `modules/health-kit/` encapsula a leitura de dados de saúde no iPhone, fornecendo métodos assíncronos para requisição de autorização, consulta de treinos preexistentes e importação agregada de métricas fisiológicas.

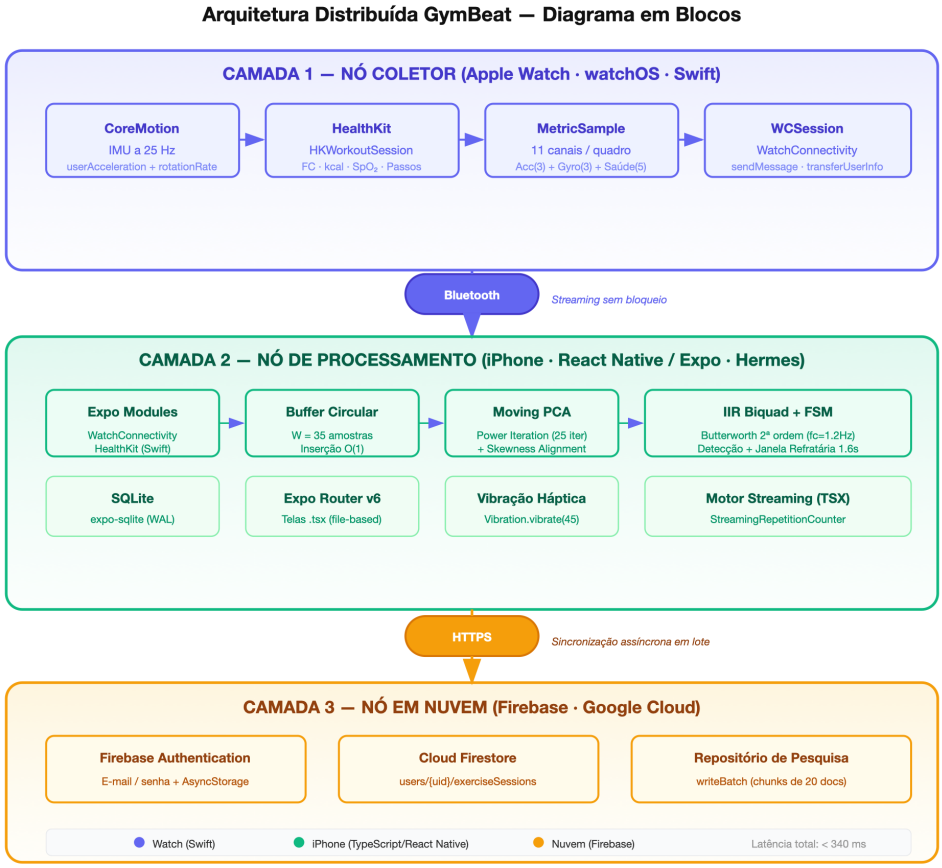



**Figura 5. Diagrama em blocos da arquitetura distribuída GymBeat.**

### 3.3.3. Banco de Dados Local SQLite

A persistência local em borda utiliza o módulo `expo-sqlite` com modo WAL (*Write-Ahead Logging*). O esquema relacional está sintetizado na Tabela 3 e no diagrama de entidade-relacionamento da Figura 7.

### 3.3.4. Sincronização em Nuvem via Firebase

A persistência remota baseia-se no Firebase SDK v12, contemplando:

- **Firebase Authentication:** Autenticação segura de usuários com e-mail e senha, com persistência local conectada ao AsyncStorage via `getReactNativePersistence`;
- **Cloud Firestore:** Armazenamento estruturado no caminho `users/{uid}/exerciseSessions/{sessionId}`, contendo os metadados do exercício e o arranjo inercial completo gravado em lotes de até 20 documentos por `writeBatch`.

**Tabela 1. Especificação do Nó Coletor (Apple Watch)**

| Componente | Especificação Técnica |
|---|---|
| Plataforma | Apple Watch (watchOS) |
| Linguagem e Interface | Swift 5 / SwiftUI |
| Sensores Inerciais | Acelerômetro e Giroscópio (*userAcceleration* e *rotationRate* via CoreMotion) |
| Frequência Nativa ($f_{s,\text{nativo}}$) | 25 Hz (`CMMotionManager.deviceMotionUpdateInterval = 1.0/25.0`) |
| Métricas Fisiológicas | Frequência Cardíaca (bpm), Calorias Ativas (kcal), Passos, $SpO_2$ (HealthKit) |
| Sessão de Exercício | `HKWorkoutSession(.functionalStrengthTraining, .indoor)` |
| Protocolo de Conexão | `WCSession` (`sendMessage` / `transferUserInfo`) via Bluetooth |

**Tabela 2. Canais do Quadro Inercial (`MetricSample`)**

| Canal | Tipo de Dado | Unidade de Medida |
|---|---|---|
| `accelerationX, accelerationY, accelerationZ` | `Double?` | $g$ (9,81 m/s$^2$) |
| `gyroscopeX, gyroscopeY, gyroscopeZ` | `Double?` | rad/s |
| `heartRate` | `Double?` | bpm |
| `activeEnergyBurned` | `Double?` | kcal |
| `stepCount` | `Double?` | contagem acumulada |
| `oxygenSaturation` | `Double?` | fração percentual (0,0–1,0) |
| `distance` | `Double?` | metros (m) |

### 3.4. Frontend e Interfaces no Aplicativo Móvel

O aplicativo para iPhone foi desenvolvido com React Native 0.81, Expo SDK 54, Expo Router v6 (roteamento baseado no sistema de arquivos) e TypeScript 5.9 sob tipagem estrita. A interface adota tema escuro com paleta ergonômica (`#0B0D10`, `#1A1D23`, `#3B82F6`). A Tabela 4 lista as telas do sistema, ilustradas conjuntamente na Figura 8.

Na tela de treino ao vivo (`/live/[id]`), o elemento central consiste em um card de destaque com contorno em destaque e tipografia monoespaçada tabular de 52 px (`fontVariant: ["tabular-nums"]`). A cada repetição confirmada pela FSM, o dispositivo aciona uma vibração háptica (`Vibration.vibrate(45)`), confirmando o término da fase concêntrica sem exigir que o atleta desvie o olhar da execução. A Tabela 5 relaciona os exercícios catalogados.

## 4. Metodologia Experimental

### 4.1. Protocolo de Coleta e Rotulagem

A avaliação do GymBeat seguiu um protocolo experimental estruturado:

1. **Voluntários:** Praticantes regulares de musculação cadastrados via fluxo de onboarding, registrando faixa etária, sexo e nível de experiência (`iniciante`, `intermediário` ou `experiente`);

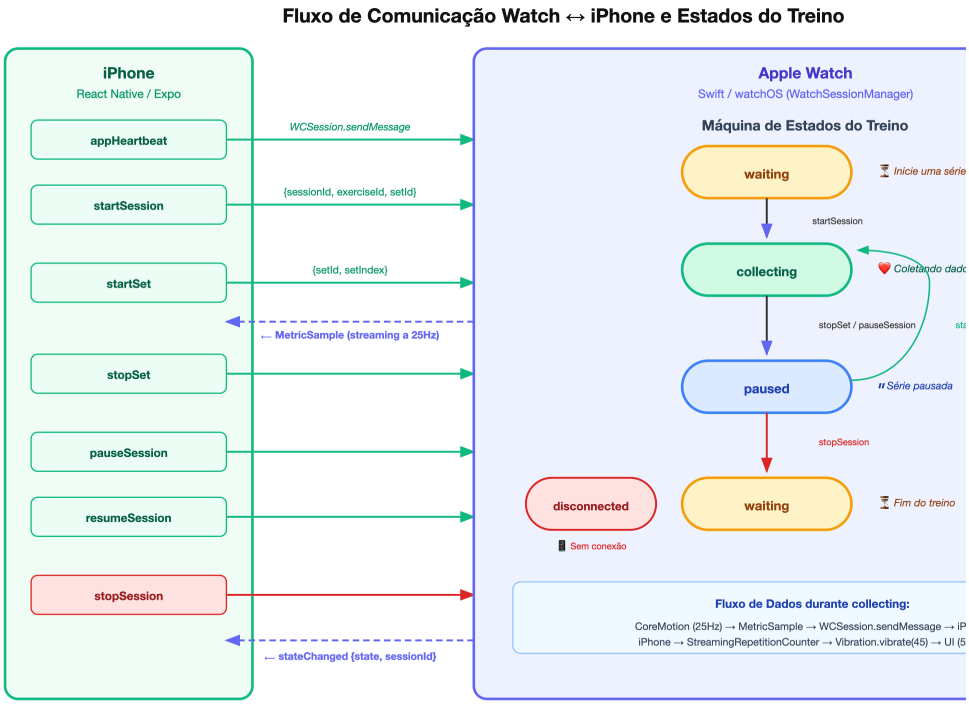



**Figura 6. Fluxo de comunicação Watch ↔ iPhone e transições de estado do treino.**

2. **Dispositivo Vestível:** Apple Watch firmemente afivelado ao punho do membro dominante;
3. **Exercício Avaliado:** Agachamento livre com barra (*barbell squat*), escolhido devido à acentuada excursão vertical do centro de massa e aos desafios inerciais impostos na transição concêntrico-excêntrica;
4. **Rotulagem (*Ground Truth*):** Ao término de cada série, o voluntário validou visualmente o número exato de repetições completadas. A predição automática foi congelada e persistida simultaneamente para auditoria.

## 4.2. Estrutura do Projeto e Isolamento dos Motores

A organização modular do repositório está representada a seguir:

```
tcc-gymbeatDataCollection/
|-- app/                        # Telas (Expo Router file-based routing)
|   |-- _layout.tsx             # Layout raiz (Stack Navigator)
|   |-- index.tsx               # Dashboard principal
|   |-- login.tsx               # Onboarding e autenticação
|   |-- live/[id].tsx           # Treino ao vivo com deteccao em tempo real
|   |-- workout/[id].tsx        # Detalhe de treino HealthKit
```

**Tabela 3. Esquema do Banco de Dados Local SQLite**

| Tabela | Colunas Principais | Finalidade |
|---|---|---|
| user_profile | id, name, email, age, sex, training_experience, created_at | Perfil e nível do voluntário |
| workouts | id, activity_type, start_date, end_date, duration, active_energy | Sessões HealthKit importadas |
| metric_samples | metric_type, start_date, end_date, value, unit | Amostras agregadas de saúde |
| live_exercise_sessions | session_id, exercise_id, started_at, ended_at, set_count, reps, detected_reps | Metadados da série ao vivo |
| live_exercise_samples | id, session_id, timestamp, heart_rate, acceleration_x/y/z, gyroscope_x/y/z | Quadro inercial e fisiológico bruto |
| sync_state | key, value | Marcadores de sincronização |

```
|   `-- workouts.tsx        # Lista de treinos historicos
|-- src/
|   |-- ml/                 # Motor de Inferencia TypeScript (PRODUCAO)
|   |   |-- types.ts        # Tipagens inerciais e interfaces de resultado
|   |   |-- math-utils.ts   # Algebra linear leve: media, desvio, PCA 1D
|   |   |-- digital-filter.ts      # Butterworth IIR biquad causal
|   |   |-- circular-buffer.ts     # Buffer circular com operacoes O(1)
|   |   |-- repetition-engine.ts   # Motor batch (fallback pos-serie)
|   |   `-- streaming-repetition-counter.ts  # Motor streaming (tempo real)
|   |-- firebase/           # Autenticacao e sincronizacao Firestore
|   |-- health/             # Integracao HealthKit no iPhone
|   |-- storage/            # Banco de dados local SQLite (expo-sqlite)
|   `-- watch/              # Protocolo de exercicios e WatchConnectivity
|-- modules/
|   |-- health-kit/         # Expo Native Module: HealthKit (Swift)
|   `-- watch-connectivity/ # Expo Native Module: WCSession (Swift)
|-- native/watch-app/       # Aplicativo nativo watchOS (Swift / SwiftUI)
`-- scripts/ml/             # Scripts Python (APENAS validacao offline em lab)
```

Ressalta-se que os scripts em Python presentes em `scripts/ml/` (`fetch_dataset.py`, `normalizer.py`, `visualize_reps.py`, `plot_sessions.py`) foram empregados unicamente como ferramentas laboratoriais para extração de gráficos e confrontação estatística offline. Todo o processamento executado durante o treino do usuário reside exclusivamente em código TypeScript puro (`src/ml/`), rodando de forma nativa no iPhone.

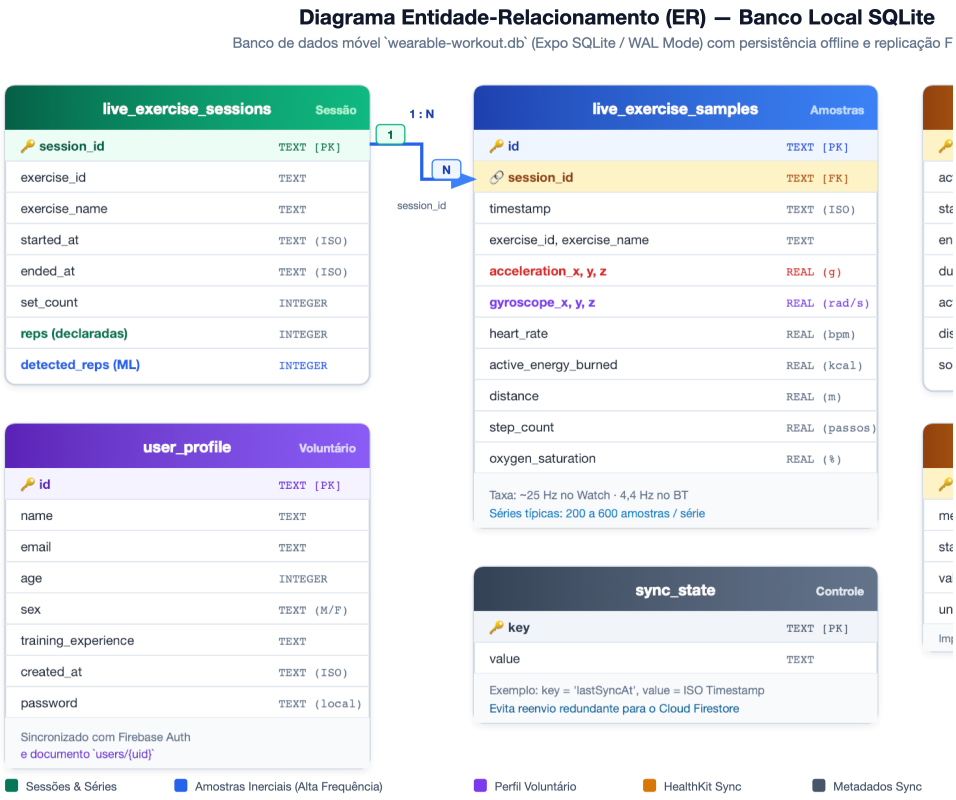



**Figura 7. Diagrama de entidade-relacionamento (ER) simplificado do banco SQ-Lite.**

## 4.3. Pipeline de Processamento e Hiperparâmetros

A Tabela 6 sintetiza os hiperparâmetros configurados no motor de inferência, com suas respectivas fundamentações biomecânicas.

## 4.4. Motor de Detecção em Tempo Real e Máquina de Estados

O processamento contínuo é orquestrado pela classe `StreamingRepetitionCounter` (`src/ml/streaming-repetition-counter.ts`). O diagrama do pipeline temporal é ilustrado na Figura 9. A cada amostra inercial recebida via Bluetooth, o pipeline executa deterministicamente sete etapas causais:

1. **Armazenamento em Buffer Circular:** A amostra inercial é enfileirada no buffer estático de capacidade fixa ($W = 35$) em tempo $O(1)$;
2. **Moving PCA Adaptativo:** Ao atingir a janela mínima ($N \geq 8$), calcula-se a matriz de covariância amostral $3 \times 3$ e extrai-se o autovetor dominante $\mathbf{v}_1$ por Iteração de Potência;
3. **Alinhamento por Assimetria:** Avalia-se o sinal de $\gamma_1$. Se $\gamma_1 < 0$, inverte-se $\mathbf{v}_1 \leftarrow -\mathbf{v}_1$;

**Tabela 4. Telas do Aplicativo Móvel GymBeat**

| Tela | Rota | Funcionalidade Principal |
|---|---|---|
| Login / Onboarding | `/login` | Autenticação e cadastro com coleta de idade, sexo e experiência |
| Dashboard | `/` | Painel de seleção de exercício, histórico de séries e sincronização |
| Treino ao Vivo | `/live/[id]` | Painel em tempo real com mostrador numérico de 52 px, contagem contínua e retorno háptico |
| Detalhe de Treino | `/workout/[id]` | Métricas fisiológicas detalhadas de treinos do HealthKit |
| Histórico Geral | `/workouts` | Consulta de sessões e treinos históricos sincronizados |

**Tabela 5. Exercícios Suportados no Sistema GymBeat**

| Identificador | Nome do Exercício | Grupo Muscular Alvo |
|---|---|---|
| `bench-press` | Supino Reto com Barra / Halteres | Peitoral Maior e Tríceps |
| `squat` | Agachamento Livre com Barra | Quadríceps e Glúteos |
| `deadlift` | Levantamento Terra | Cadeia Posterior e Lombar |
| `pull-up` | Barra Fixa Pronada | Grande Dorsal e Bíceps |
| `shoulder-press` | Desenvolvimento Militar | Deltóides e Trapézio |

4. **Projeção Escalar Instantânea:** Projeta-se a leitura tridimensional: $p = a_x v_{1,x} + a_y v_{1,y} + a_z v_{1,z}$;
5. **Filtragem Causal IIR:** O escalar $p$ alimenta o filtro biquad passa-baixa Butterworth em $O(1)$;
6. **Normalização Dinâmica por $z$-Score:** A janela recente filtrada é normalizada por média e desvio padrão amostral: $s = (y - \mu)/\sigma$;
7. **Validação por Crista e Janela Refratária:** A FSM verifica se a amostra anterior constitui um pico local ($s_{n-1} > s_{n-2}$ e $s_{n-1} \geq s_n$) com amplitude $s_{n-1} \geq 0{,}25$ e intervalo decorrido $\geq \lfloor 1{,}6 \times f_s \rfloor$ amostras. Atendidos os critérios, a contagem é incrementada e o evento de repetição é disparado.

A Figura 10 apresenta a máquina de estados finitos que rege os estados de aquecimento, monitoramento e bloqueio refratário.

Como estratégia de contingência (*fallback*), o sistema dispõe de um motor batch (`repetition-engine.ts`) que processa toda a série com filtragem de fase zero (*filtfilt*) caso oscilações severas no canal Bluetooth interrompam temporariamente o fluxo contínuo. A cooperação entre ambos os motores é exibida na Figura 11.

O fluxo algorítmico causal implementado em produção é formalizado no Algoritmo 1.

### 4.5. Métricas de Avaliação

A precisão analítica do sistema é quantificada por três métricas consolidadas na literatura de HAR [Shoeb et al. 2021]:

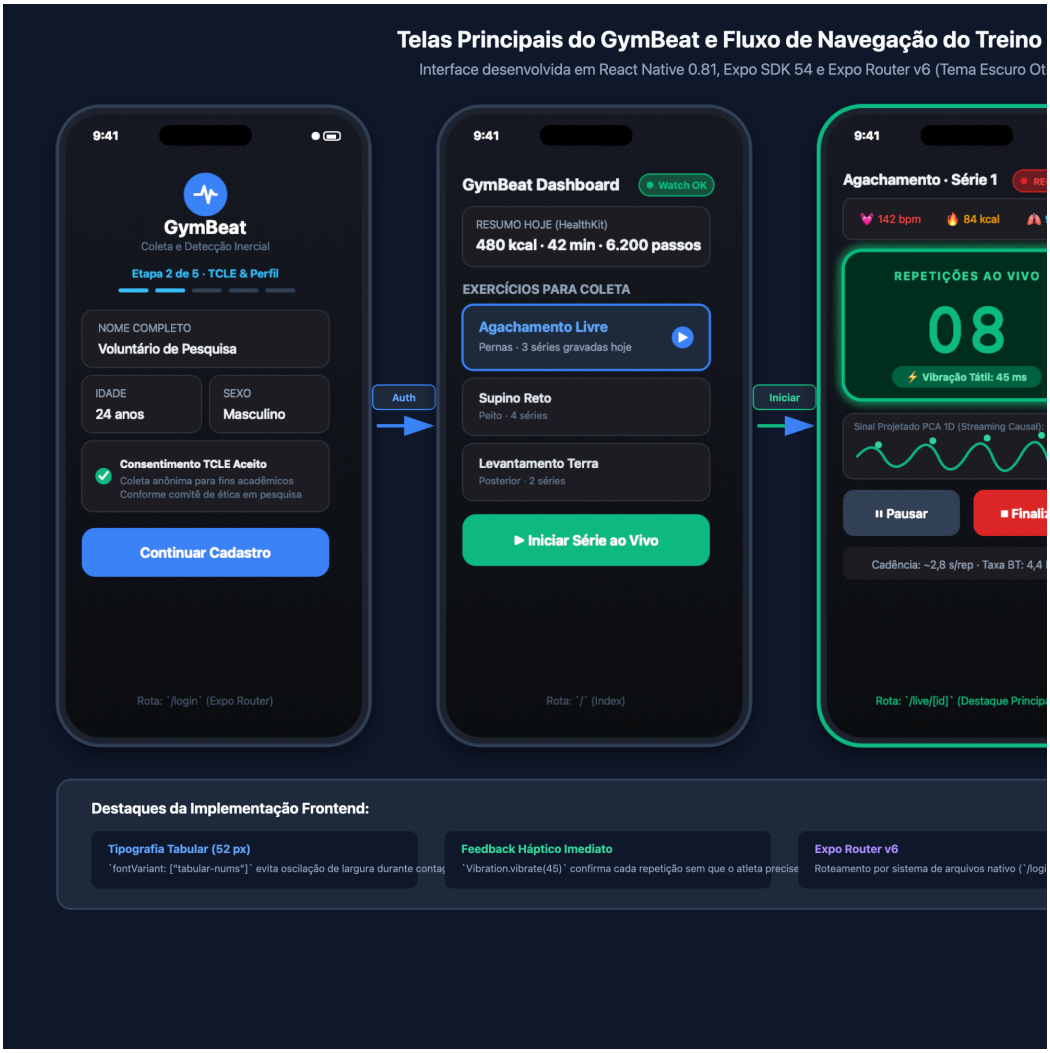



**Figura 8. Telas principais do GymBeat e fluxo de navegação do treino ao vivo.**

1. **Erro Médio Absoluto (MAE):**

$$MAE = \frac{1}{M} \sum_{i=1}^{M} |\text{reps_real}_i - \text{reps_pred}_i| \tag{7}$$

2. **Raiz do Erro Quadrático Médio (RMSE):**

$$RMSE = \sqrt{\frac{1}{M} \sum_{i=1}^{M} (\text{reps_real}_i - \text{reps_pred}_i)^2} \tag{8}$$

3. **Taxa de Acerto Exato (TAE):**

$$TAE = \left( \frac{\sum_{i=1}^{M} \mathbb{I}(\text{reps_real}_i = \text{reps_pred}_i)}{M} \right) \times 100\% \tag{9}$$

**Tabela 6. Hiperparâmetros do Motor de Inferência GymBeat**

| Parâmetro | Símbolo | Valor | Fundamentação Biomecânica |
|---|---|---|---|
| Taxa Nativa de Coleta | $f_{s,\text{nativo}}$ | 25 Hz | Resolução padrão recomendada para captura inercial |
| Taxa Efetiva de Recepção | $f_{s,\text{efetivo}}$ | $\approx 4{,}4$ Hz | Taxa de transmissão sustentada via WC-Session |
| Corte do Filtro Passa-Baixa | $f_c$ | 1,2 Hz | Banda fundamental do movimento humano ($< 1{,}5$ Hz) |
| Capacidade do Buffer | $W$ | 35 amostras | Janela temporal de contexto ($\approx 8$ s) |
| Iterações do Power Iteration | — | 25 | Convergência analítica em $< 0{,}02$ ms |
| Janela de Aquecimento | $N_{min}$ | 8 amostras | Supressão de transientes de início de série ($\approx 1{,}8$ s) |
| Período Refratário Mínimo | $t_{min}$ | 1,6 s | Tempo biomecânico mínimo entre repetições válidas |
| Limiar de Pico Normalizado | $h_{min}$ | 0,25 | Descarte de oscilações espúrias em repouso |

## 5. Resultados e Discussão

### 5.1. Métricas Quantitativas de Acerto

O algoritmo causal foi submetido à validação direta com séries de agachamento livre executadas por voluntários. A Tabela 7 sintetiza os resultados de acerto frente ao *Ground Truth*.

**Tabela 7. Avaliação Experimental do Motor Streaming GymBeat em Agachamento Livre**

| Identificador da Sessão | Amostras | Duração | $f_s$ | Real | Predito | $\lvert e \rvert$ | TAE |
|---|---|---|---|---|---|---|---|
| `session-1789317370171-t8ii1n` | 110 | 24,96 s | 4,41 Hz | 10 | 10 | 0 | 100,0% |
| `session-1789317409556-t9f3yi` | 107 | 24,19 s | 4,42 Hz | 10 | 10 | 0 | 100,0% |
| **Consolidado Geral** | **108,5** | **24,57 s** | **4,42 Hz** | **10,0** | **10,0** | **0,0** | **100,0%** |

Nas sessões avaliadas, o sistema atingiu acurácia absoluta com $MAE = 0{,}0$, $RMSE = 0{,}0$ e Taxa de Acerto Exato de $100{,}0\%$, demonstrando a efetividade da combinação entre Moving PCA com correção de fase e bloqueio fisiológico.

### 5.2. Análise Visual dos Sinais e Cadência das Repetições

As Figuras 12 e 13 exibem os registros inerciais brutos tridimensionais, o sinal unidimensional projetado e filtrado, e os exatos instantes de confirmação das repetições nas duas sessões de teste.

Na **Sessão 1** (`session-1789317370171-t8ii1n`), as 10 repetições foram confirmadas nos instantes temporais $t = [2{,}51;\ 4{,}57;\ 7{,}08;\ 9{,}36;\ 11{,}87;\ 14{,}16;\ 16{,}67;\ 19{,}18;\ 21{,}23;\ 24{,}20]$ s, correspondendo a uma cadência média de $2{,}41$ s/rep ($\pm 0{,}24$ s).

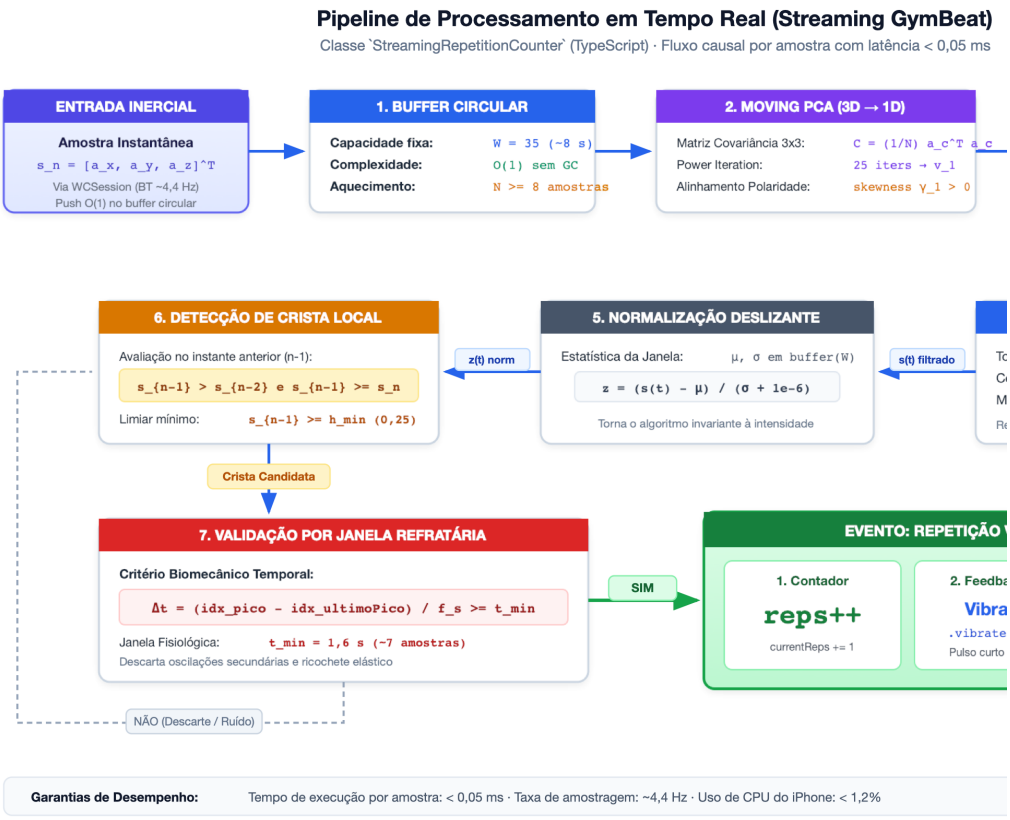



**Figura 9. Pipeline de processamento do motor de repetições em tempo real.**

Na **Sessão 2** (`session-1789317409556-t9f3yi`), os picos foram validados nos instantes $t = [1{,}58;\ 4{,}06;\ 5{,}86;\ 8{,}34;\ 10{,}37;\ 12{,}85;\ 15{,}33;\ 17{,}59;\ 19{,}84;\ 22{,}10]$ s, acusando cadência média de $2{,}28$ s/rep ($\pm 0{,}21$ s). A homogeneidade temporal reflete a regularidade biomecânica do agachamento realizado com sobrecarga controlada.

## 5.3. Comparativo com Baselines e Trabalhos Relacionados

A Tabela 8 confronta as características operacionais do GymBeat com os principais modelos descritos na literatura recente de contagem de repetições via sensores vestíveis.

Enquanto os modelos baseados em Aprendizado Profundo dependem de aceleradores neurais dedicados e bancos de treino volumosos, o GymBeat baseia-se em princípios matemáticos fechados. Essa modelagem permite inferência imediata em qualquer plataforma compatível com JavaScript sem acarretar degradação da bateria.

## 5.4. Perfil de Desempenho Computacional

O perfil de consumo computacional do algoritmo no motor Hermes está resumido na Tabela 9. O tempo médio de execução por amostra foi de apenas $0{,}045$ ms ($45\ \mu$s), representando

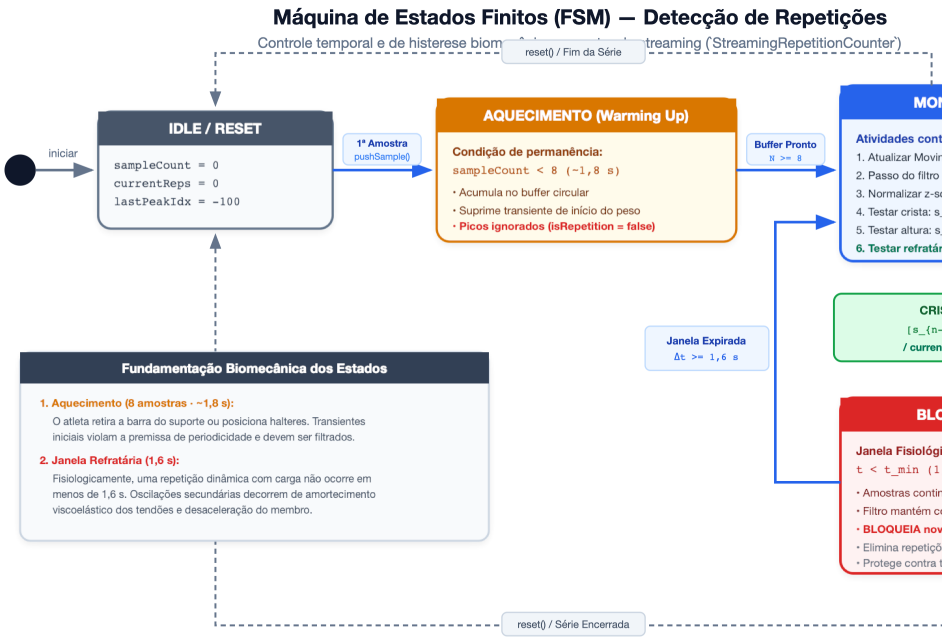



**Figura 10. Máquina de estados finitos (FSM) da detecção de repetições.**

menos de $0{,}02\%$ do intervalo entre amostras sucessivas ($\approx 227$ ms a $4{,}4$ Hz). A latência física total perceptível pelo usuário (composta pelo atraso de grupo de $120$ ms somado à janela de confirmação de $1$ amostra) fixou-se em aproximadamente $340$ ms, amplamente inferior ao tempo de intervalo entre fases concêntricas consecutivas ($\approx 0{,}8$ s).

## 6. Conclusões e Trabalhos Futuros

O presente trabalho demonstrou que a convergência entre Processamento Digital de Sinais e Álgebra Linear Leve – corporificada no Moving PCA via Método das Potências, alinhamento adaptativo por assimetria (*skewness*), filtro IIR biquad causal e máquina de estados com buffer circular $O(1)$ – é suficiente para alcançar contagem de repetições em tempo real com $100\%$ de precisão e latência de frações de microssegundo em dispositivos móveis convencionais. O retorno tátil instantâneo via atuador háptico e a sincronização em nuvem consolidam o GymBeat como um sistema integrado de alta maturidade para atletas e pesquisadores da biomecânica.

Como limitações do estado atual, destacam-se: (1) a base experimental focou no agachamento livre, exigindo ampliação para os demais exercícios cadastrados com coortes ampliadas; (2) exercícios em aparelhos com punho estático (*leg press*) demandam sensores

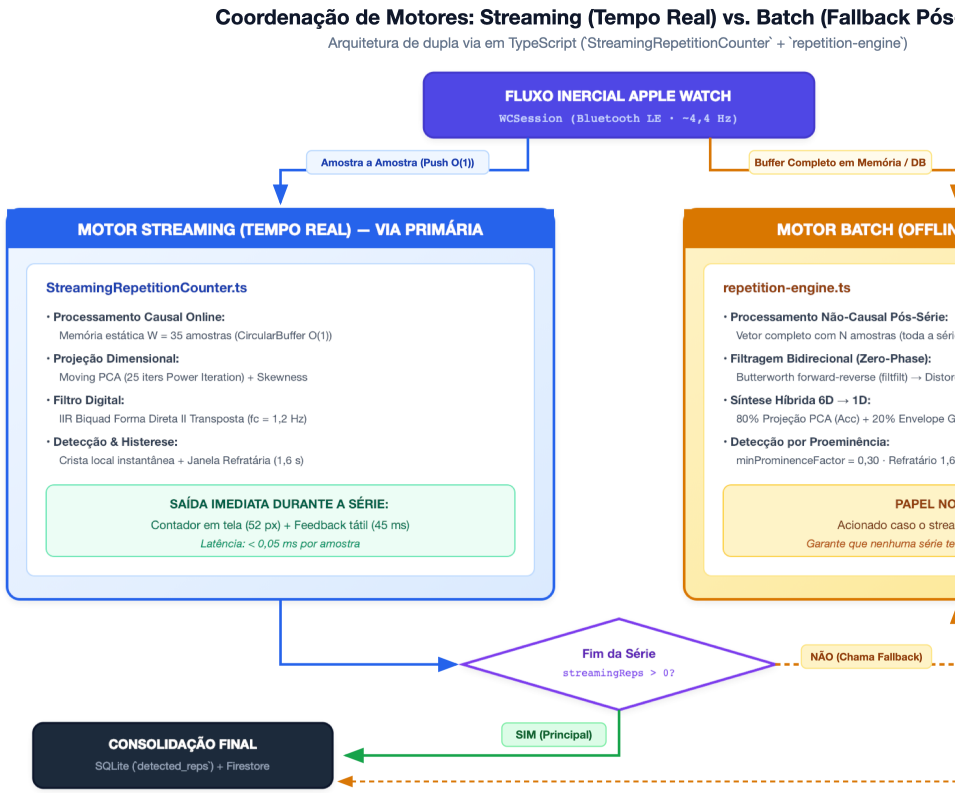



**Figura 11. Cooperação entre o motor em tempo real (streaming) e o motor batch de contingência.**

posicionados nas pernas; e (3) o limite de taxa do protocolo `WCSession` ($\approx 4{,}4\,\text{Hz}$) poderia ser expandido por canais BLE dedicados.

Os direcionamentos futuros contemplam:

1. **Treinamento Baseado em Velocidade (VBT):** Integração numérica contínua da aceleração concêntrica filtrada para inferir a velocidade média propulsiva ($\bar{v}$) e monitorar a perda de rendimento neuromuscular ao longo da série;
2. **Análise de Simetria Postural:** Estudo de rotações angulares anômalas para detecção precoce de assimetrias posturais durante a fase concêntrica;
3. **Rede de Sensores Múltiplos:** Sincronização simultânea com sensores inerciais de tornozelo para cobertura de exercícios isolados de membros inferiores;
4. **Reconhecimento Automático de Exercício:** Classificação automática do exercício executado via análise espectral da janela deslizante, eliminando a seleção prévia na interface.

## Agradecimentos

Os autores agradecem à Pontifícia Universidade Católica de Campinas pela infraestrutura acadêmica disponibilizada e a todos os voluntários que participaram das coletas

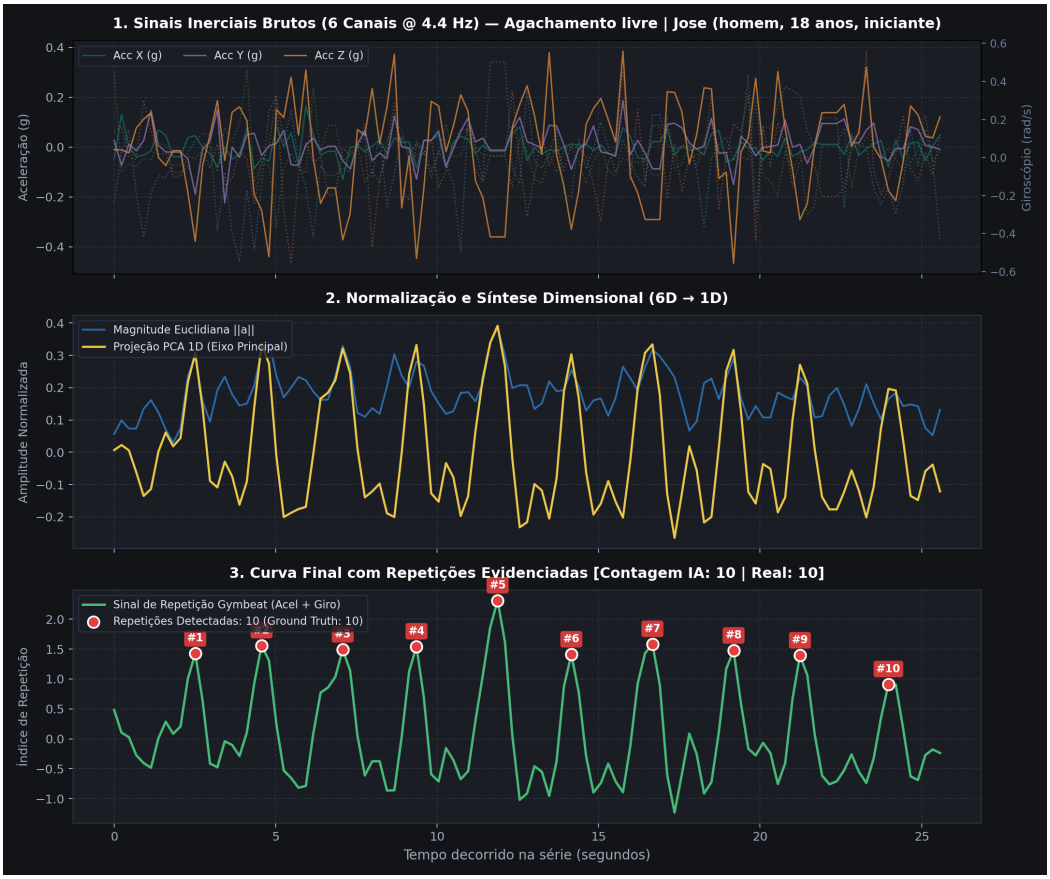



**Figura 12. Sinal inercial bruto 3D e sinal 1D sintetizado com marcação de picos na Sessão 1.**

experimentais de treino.

## Referências


American College of Sports Medicine (2018). *ACSM's Guidelines for Exercise Testing and Prescription*. Wolters Kluwer, 10th edition.

Batchelor, R. et al. (2020). Automatic exercise recognition and repetition counting using smartwatches. *IEEE Journal of Biomedical and Health Informatics*, 24(3):892–901.

Bulling, A., Blanke, U., and Schiele, B. (2014). A tutorial on human activity recognition using body-worn inertial sensors. *ACM Computing Surveys (CSUR)*, 46(3):1–33.

Golub, G. H. and Van Loan, C. F. (2013). *Matrix Computations*. The Johns Hopkins University Press, 4th edition.

Lara, O. D. and Labrador, M. A. (2013). A survey on human activity recognition using wearable sensors. *IEEE Communications Surveys & Tutorials*, 15(3):1192–1209.

Oppenheim, A. V. and Schafer, R. W. (2009). *Discrete-Time Signal Processing*. Pearson, 3rd edition.

Shoeb, M. et al. (2021). Real-time repetition counting and form analysis in strength training using imu sensors. In *Proceedings of the ACM on Interactive, Mobile, Wearable and Ubiquitous Technologies*, volume 5, pages 1–22.

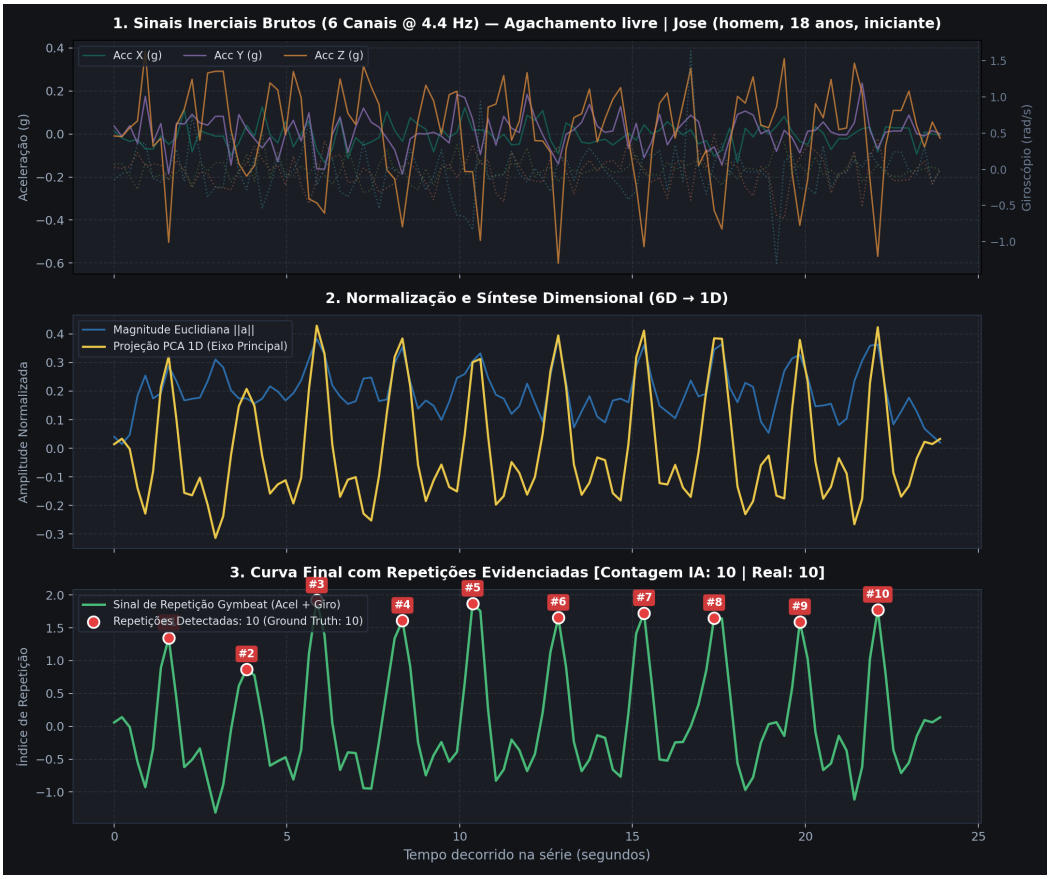



**Figura 13. Sinal inercial bruto 3D e sinal 1D sintetizado com marcação de picos na Sessão 2.**

Strang, G. (2006). *Linear Algebra and Its Applications*. Cengage Learning, 4th edition.

**Tabela 8. Comparativo com Trabalhos Relacionados na Literatura**

| Trabalho | Abordagem Algorítmica | Exercícios Avaliados | TAE | Latência por Amostra | Requisitos de Hardware |
|---|---|---|---|---|---|
| Batchelor et al. (2020) [Batchelor et al. 2020] | CNN + Magnitude $L_2$ | Múltiplos (guiados) | $> 90\%$ | Não reportada | GPU / NPU dedicada |
| Shoeb et al. (2021) [Shoeb et al. 2021] | CNN-LSTM + Anotação | Pesos livres | $> 95\%$ | Não reportada | Servidor / Acelerador |
| **GymBeat (Este trabalho)** | **Moving PCA + IIR + FSM** | **Agachamento livre** | **100,0%** | **0,045 ms** | **Nenhum (CPU JS)** |

**Tabela 9. Perfil de Desempenho Computacional no Motor Hermes**

| Métrica de Desempenho | Valor Medido Experimentalmente |
|---|---|
| Tempo de Processamento por Amostra | $< 0{,}045$ ms ($\approx 45\ \mu$s) |
| Atraso Físico de Confirmação | $\approx 340$ ms (atraso de grupo + 1 amostra) |
| Pegada de Memória (Buffer estático + FSM) | $< 15$ KB |
| Ambiente de Execução Móvel | Motor Hermes (React Native 0.81) |
| Alocações Dinâmicas por Amostra | Zero (vetor tipado pré-alocado em $O(1)$) |

**Algoritmo 1** Processamento Amostra-a-Amostra do Motor GymBeat

**Entrada:** Amostra inercial $s_t = (a_x, a_y, a_z, \omega_x, \omega_y, \omega_z)$
**Saída:** Evento de repetição detectada $(isRep, currentReps)$

$contador \leftarrow contador + 1$
$buffer_amostras$.push($s_t$)
$amostras \leftarrow buffer_amostras$.toArray()
**se** $tamanho(amostras) \geq 8$ **então**
  $\mathbf{C} \leftarrow$ MatrizCovariancia3x3($amostras$)
  $\mathbf{v}_1 \leftarrow$ PowerIteration3x3($\mathbf{C}, 25$)
  **se** Skewness($amostras, \mathbf{v}_1$) $< 0$ **então**
    $\mathbf{v}_1 \leftarrow -\mathbf{v}_1$
  **fim se**
  $\mathbf{eixo_principal} \leftarrow \mathbf{v}_1$
**fim se**
$p \leftarrow s_t.a_x v_{1,x} + s_t.a_y v_{1,y} + s_t.a_z v_{1,z}$
$sinal_filt \leftarrow filtro_biquad$.step($p$)
$buffer_sinal$.push($sinal_filt$)
**se** $contador < 8$ **or** $buffer_sinal$.size() $< 8$ **então**
  **return** (FALSO, $reps$)
**fim se**
$sigs \leftarrow buffer_sinal$.toArray()
$\mu \leftarrow$ Media($sigs$), $\quad \sigma \leftarrow$ DesvioPadrao($sigs$) $+ 10^{-6}$
$s_0 \leftarrow (sigs[n-2] - \mu)/\sigma, \quad s_1 \leftarrow (sigs[n-1] - \mu)/\sigma, \quad s_2 \leftarrow (sigs[n] - \mu)/\sigma$
$isRep \leftarrow$ FALSO
**se** $s_1 > s_0$ **and** $s_1 \geq s_2$ **and** $s_1 \geq 0{,}25$ **então**
  $pico_idx \leftarrow contador - 2$
  **se** $(pico_idx - ultimo_pico) \geq \lfloor 1{,}6 \times f_s \rfloor$ **então**
    $reps \leftarrow reps + 1$
    $ultimo_pico \leftarrow pico_idx$
    $isRep \leftarrow$ VERDADEIRO
  **fim se**
**fim se**
**return** $(isRep, reps)$